# Détection vidéo des crises épileptiques assistée par IA

## Analyse du mouvement et classification par CNN, SVM et Régression


Étudiant : **Anthony Kouam**

Encadrant : **Laurent Albera**

Université de Rennes 1
Laboratoire Traitement du Signal et de l'Image (LTSI)
Campus de Beaulieu, F-35042 Rennes, France


Février 2026






**Plan de la présentation**


- **I. Introduction :** Contexte et Problématique
- **II. Prétraitement :** Optical Flow et descripteurs FlowFeat
- **III. Analyse :** Visualisation temporelle et fréquentielle (FFT)
- **IV. Architecture des modèles :** Régression, SVM et CNN 1D
- **V. Résultats :** Performances comparées et matrices de confusion
- **VI. Conclusion et perspectives**

**Enjeux de la détection automatique**

.

- Objectif : Développer un outil d'aide au diagnostic non invasif par analyse vidéo.
- Données : Base de données équilibrée de 2 000 clips vidéos de 10 secondes (classes : Normal vs Crise).

**Aperçu Vidéo**




**Cliquez pour lire une vidéo**

**Hypothèse**

$$I(x, y, t) = I(x + \delta x, y + \delta y, t + \delta t)$$

$$\underbrace{\frac{\partial I}{\partial x}u + \frac{\partial I}{\partial y}v}_{\text{Spatial}} + \underbrace{\frac{\partial I}{\partial t}}_{\text{Temporel}} = 0$$

**Extraction du mouvement**

- $u, v$ : Déplacements horizontaux/verticaux.

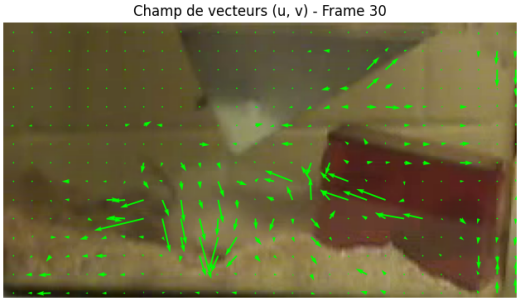



Figure – Champ de vecteurs $\vec{V}(u, v)$ sur une frame de crise

- Signature de crise : Directions désordonnées et forte magnitude ($\sqrt{u^2 + v^2}$).

**Réduction de dimensions**

Pour chaque frame, le champ de vecteurs est réduit à 3 outils statistiques :

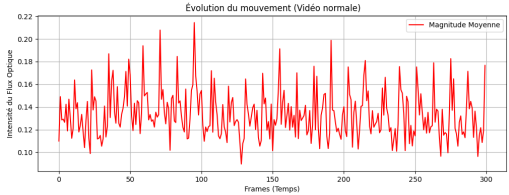
$$\text{FlowFeat}(t) = [\mu(\text{mag}), \sigma^2(\text{mag}), \max(\text{mag})]$$

- Moyenne ($\mu$) : Intensité globale du mouvement.
- Variance ($\sigma^2$) : Caractère chaotique du signal.
- Maximum : Sursauts brusques.
- Résultat : Compression des données initiales.

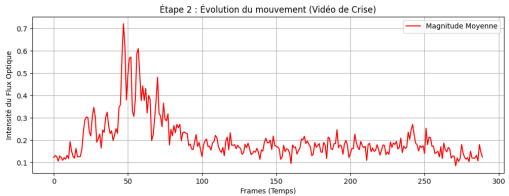
Signal 1D exploitable par des modèles d'IA.

**Dynamique du mouvement**

Comparaison des descripteurs FlowFeat sur une vidéo de 10 secondes.



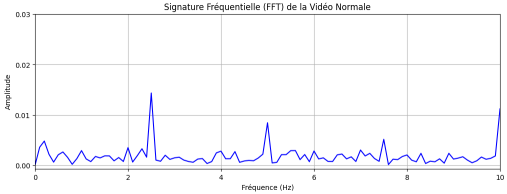

État Normal : Signal stable, faible amplitude.

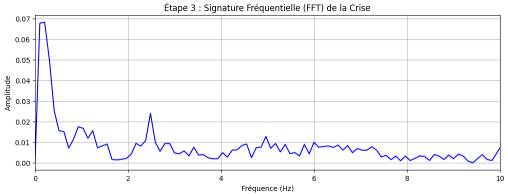



État de Crise : Pics d'intensité traduisant les secousses.

**Transformation de Fourier**

Passage dans le domaine fréquentiel pour identifier les rythmes de crise.



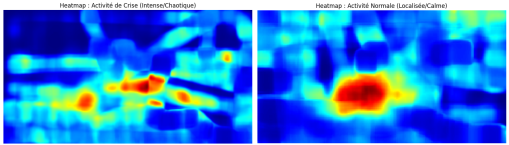



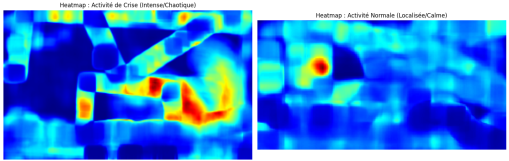

Spectre Normal : Énergie concentrée dans les très basses fréquences (mouvements lents).

Spectre de Crise : Apparition de pics significatifs correspondant aux secousses.

**Signature visuelle**

Observation du mouvement cumulé sur deux paires de vidéos distinctes.



**Régression Logistique**

**Approche :** Linéaire → Probabilité

- **Équation de décision :**

$$z = w \cdot x + b$$

- **Fonction d'activation :**

$$P(\text{Crise}) = \frac{1}{1 + e^{-z}}$$

**SVM (Kernel RBF)**

**Approche :** Maximisation de la marge

- **Transformation RBF :**
- **Noyau RBF (Gaussien) :**

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2\right)$$

- **Optimisation :**

$$\text{Marge} \propto \frac{1}{\|w\|}$$

**Structure du modèle**

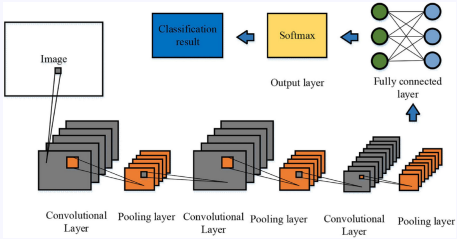



Figure – Conv1D (32, 64) → GAP → Dense

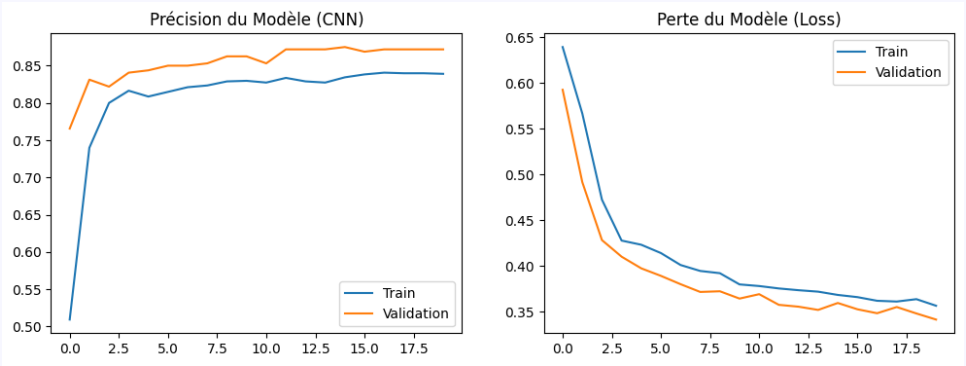
- **Input :** 300 frames × 3 features.

**Hyperparamètres**

- **Optimiseur :** Adam ($LR = 10^{-3}$).
- **Perte :** Binary Crossentropy.
- **Entraînement :** 30 Epochs.
- **Batch Size :** 32.
- **Régularisation :** Dropout (0.3).

**Décision Finale**
Activation Sigmoid pour une classification binaire (Sain vs Crise).

**Courbes d'apprentissage (Loss & Accuracy)**




- Convergence rapide vers la 20$^{\text{ème}}$ epoch.
- La *Loss* décroît progressivement jusqu'à stabilisation.

**Résultats : Classe 0 (Normal)**

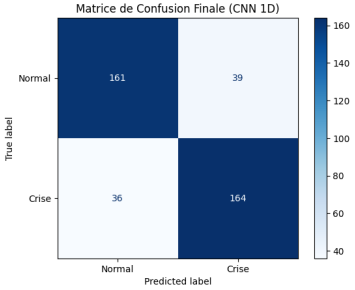
| Modèle | Précision | Rappel | F1-Score |
|---|---|---|---|
| Régression Log. | 0.76 | 0.80 | 0.78 |
| CNN | 0.82 | 0.81 | 0.81 |
| SVM (RBF) | 0.86 | 0.76 | 0.81 |

**Résultats : Classe 1 (Crise)**

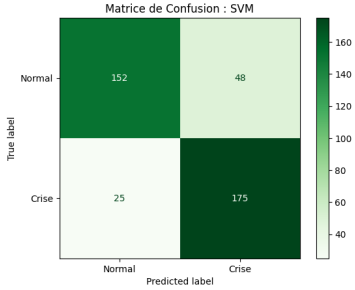
| Modèle | Précision | Rappel | F1-Score |
|---|---|---|---|
| Régression Log. | 0.79 | 0.75 | 0.77 |
| CNN | 0.81 | 0.82 | 0.81 |
| SVM (RBF) | 0.78 | 0.88 | 0.83 |

*Support : 200 échantillons par classe (Total : 400)*

# Analyse des Prédictions : Matrices de Confusion




**Performance Équilibrée**
Précision et Rappel quasi identiques.

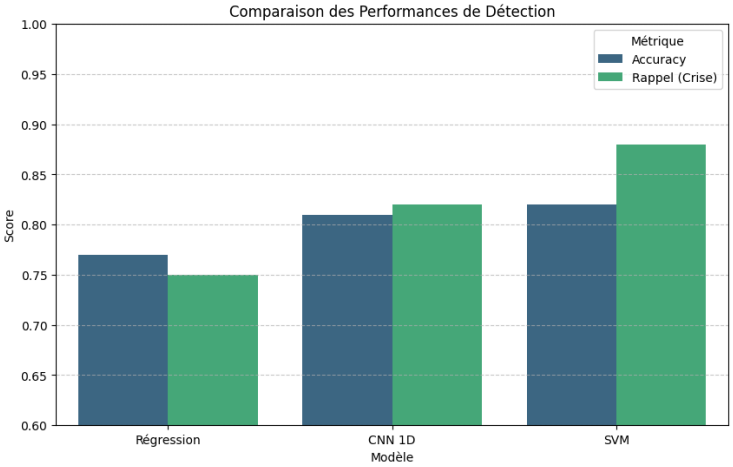



**Optimisation du Rappel**
Seulement 24 crises manquées (FN).

**Observation Clé**

Le **SVM** maximise les Vrais Positifs (175 contre 164), ce qui en fait le modèle le plus sûr dans ce cas précis.

# Performances globales



**Acquis du projet**

- Validation : L'Optical Flow couplé à FlowFeat est une méthode de compression efficace.
- Performance : Atteinte de 88% de rappel avec le SVM.
- Interprétabilité : Les heatmaps et la FFT confirment la pertinence des modèles.

**Développements futurs**

- **Temps réel :** Implémentation sur flux vidéo direct.
- **Extension :** Couplage avec l'EEG pour réduire les faux positifs.
- **Enrichissement :** Augmentation du dataset pour améliorer le CNN.

**Descripteurs de mouvement (FlowFeat)**

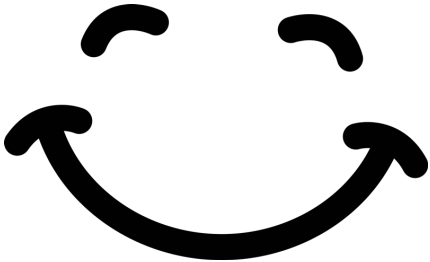

- **Araslanov, N., Sonnweber, A., & Cremers, D.** (2025). *FlowFeat : Learning Robust Flow-based Features for Video Analysis*. Advances in Neural Information Processing Systems (**NeurIPS**), Spotlight.
- Article | Matériel supplémentaire


**Fondements de l'Optical Flow**


- **Karayannis, T., et al.** (2006). *Automated detection of seizures in rodents using optical flow analysis*. Journal of Neuroscience Methods.


*Ce projet s'appuie sur l'implémentation de l'algorithme de Farneback (OpenCV) pour l'estimation du mouvement dense.*

# Merci pour votre attention !



*Questions ?*