





Université de Rennes

Laboratoire Traitement du Signal et de l'Image (LTSI)

Campus de Beaulieu, F-35042 Rennes, France

Rapport de Stage

Calibration automatique de caméra et capture de mouvement 2D d'un joueur de tennis

Présenté par :

Anthony Kouam

Tuteur de stage :

M. Laurent Albera

Année universitaire 2024–2025

Table des matières

Introduction 3

Chapitre 1 : Calibration automatique 4

1.1 Principe général 4

1.2 Résultats 5

2. Extraction des paramètres d'une caméra 6

2.1 Paramètres intrinsèques 6

2.2 Paramètres extrinsèques 7

2.3 Coefficients de distorsion 7

2.4 Résumé illustratif et résultats 7

Chapitre 2 : Capture de mouvement 10

1. Annotation manuelle 10

2. Annotation automatique 11

3. Résultats et analyse 12

Conclusion 15

Bibliographie 16

Introduction

Le projet vise à évaluer les performances d'une méthode de calibration automatique d'une caméra filmant un match de tennis et une méthode de capture de mouvement 2D du joueur au premier plan.

Plus particulièrement, l'approche de calibration automatique repose sur la détection de points clés (les 14 intersections des lignes du terrain). Quant à la capture de mouvement, elle repose sur la détection des articulations (modèle à 14 points clés) du joueur en mouvement.

Notre travail s'appuie sur l'intelligence artificielle, notamment le modèle de deep learning appelé ResNet pour la calibration automatique et le modèle YOLO (You Only Look Once) pré-entraîné pour la capture de mouvement. Il fait suite au travail de projet de fin d'étude de deux étudiants du M2 SiVOS (Lise Paschal et Lucas Philippe).

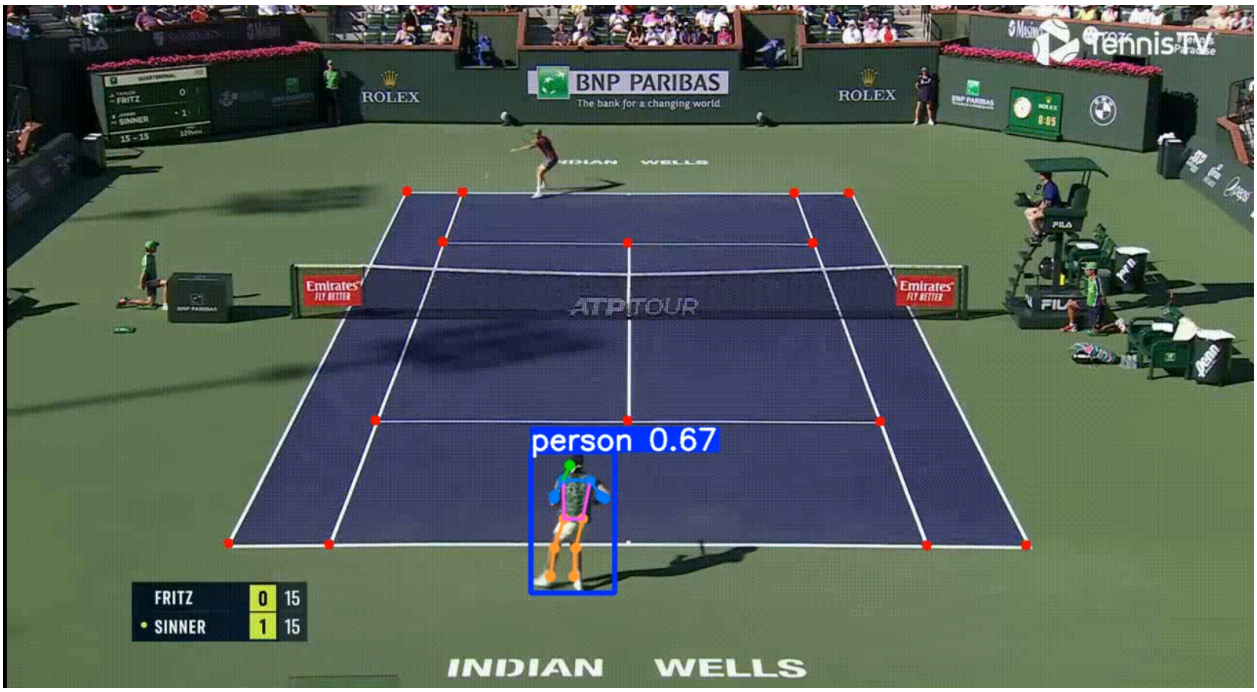


Fig. 1 – Position des 14 points clés du terrains et des 14 points clés du joueur en premier plan

Chapitre 1

Calibration automatique

1 Détection des 14 points clés

1.1 Principe général

Le pipeline de l'algorithme de détection de ces keypoints est donné ci-dessous. Notons que la base de données utilisée est constituée :

— de 8841 images de terrain,

— de données d'entraînement et de validation au format `.json`.

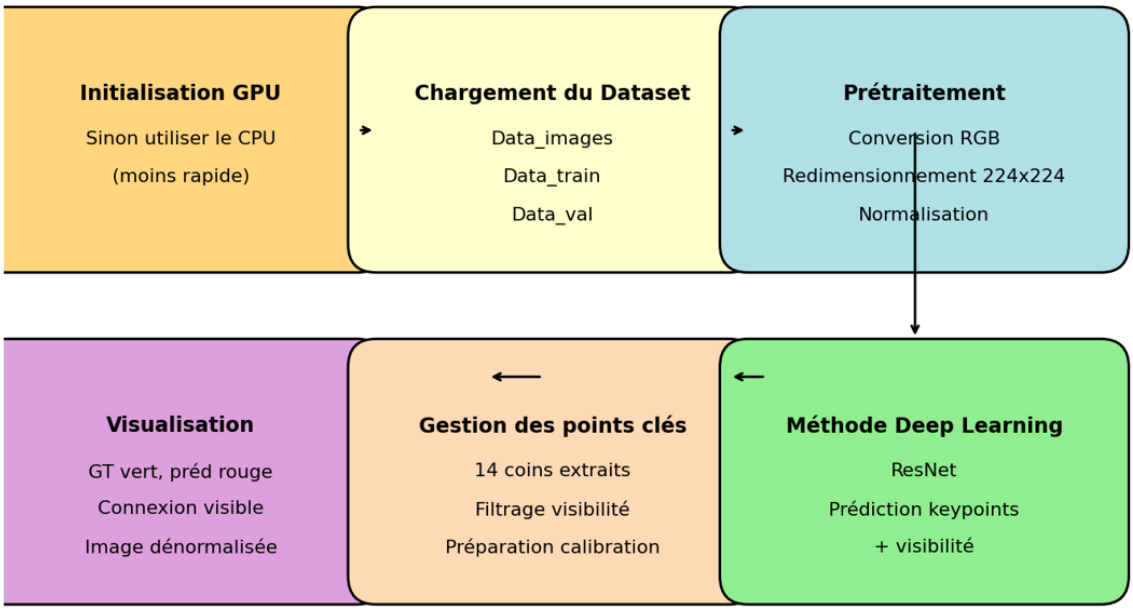


Fig. 1.1 – Synoptique de l'algorithme de calibration automatique

L'algorithme de détection des 14 points clés repose sur un réseau de neurones entraîné pour identifier les intersections des lignes du terrain. Un prétraitement est appliqué aux images afin d'améliorer la précision des détections en conditions

réelles. Cette étape est essentielle pour garantir une calibration optimale de la caméra.

Le réseau de neurones mentionné ici est le modèle ResNet [He et al. (2016)], conçu pour faciliter l'apprentissage en ajoutant des connexions résiduelles entre certaines couches. Cela permet de préserver les informations importantes tout au long du processus et d'améliorer la précision globale du modèle.

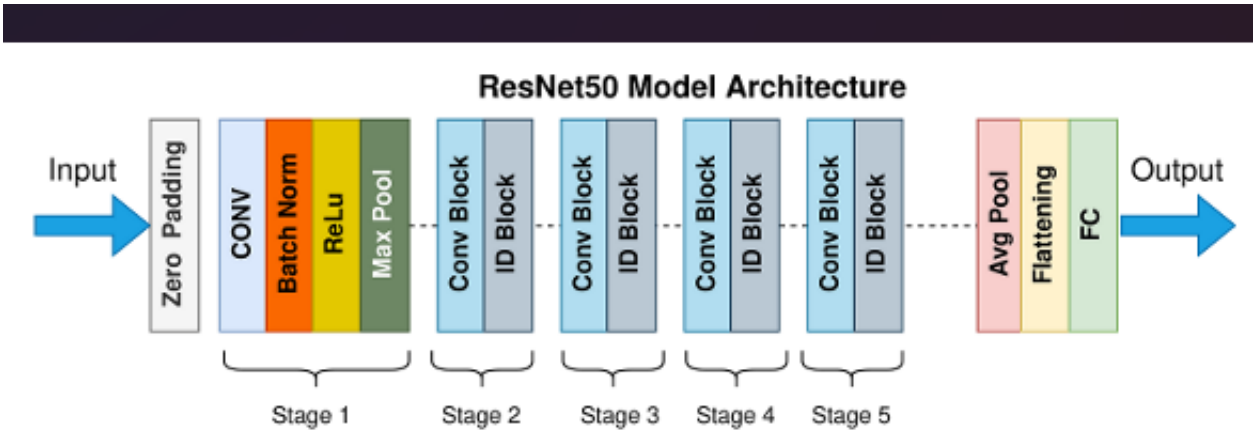


Fig. 1.2 – Croquis du modèle ResNet

1.2 Résultats

Les résultats de détection des 14 points clés sont donnés ci-dessous. La figure 1.3 illustre le bon comportement de l'algorithme en représentant en vert les points détectés. Ces résultats illustrent l'efficacité du modèle dans l'identification des points clés essentiels pour la calibration.

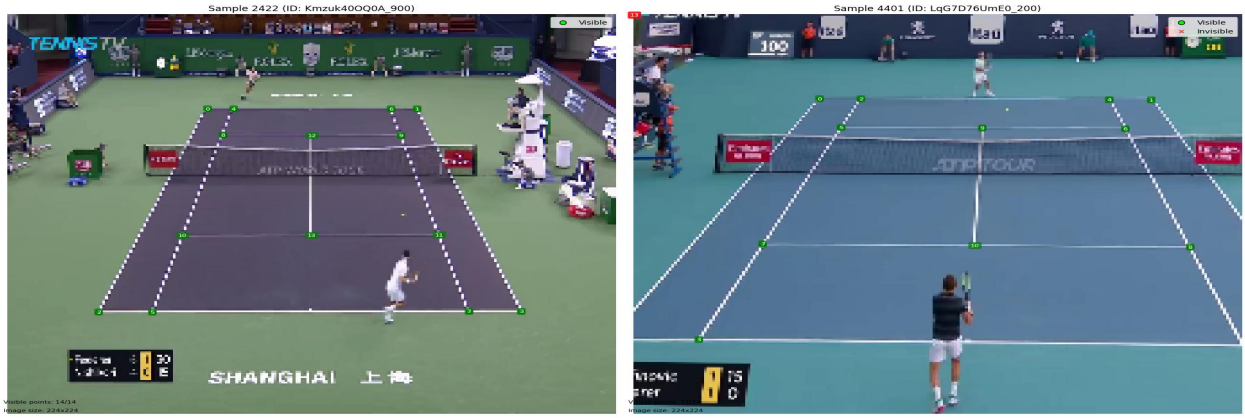


Fig. 1.3 – Résultats de détection des 14 points clés

La figure 1.4 montre quant-à-elle l'erreur d'estimation des 14 points clés sur

2210 images de test, soit 25% de la base de donnée, les autres 75% ayant été utilisés pour l'apprentissage de l'algorithme.

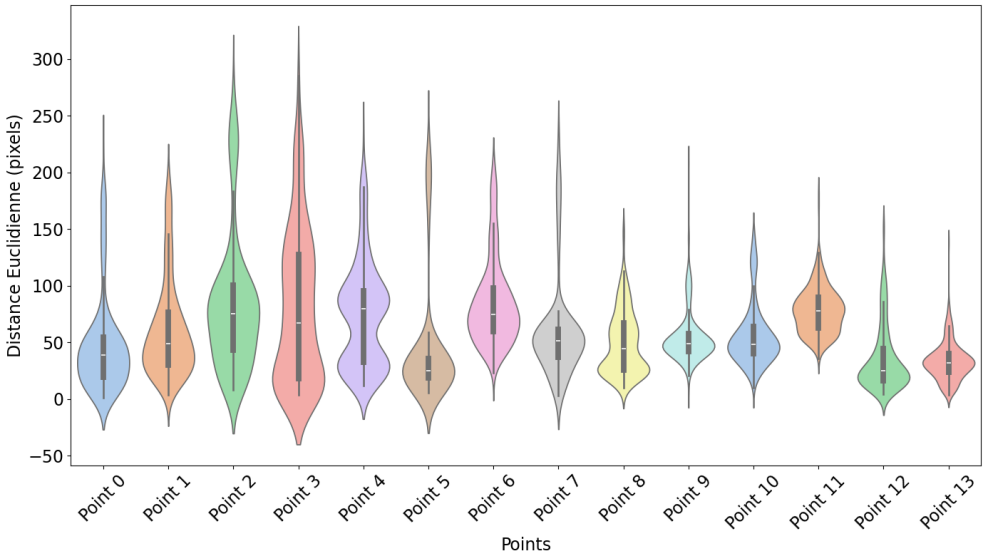


Fig. 1.4 – Distance euclidienne entre points projetés et points mesurés

Remarquons que nous obtenons une erreur moyenne sur les 14 points clés de 11 pixels.

2 Extraction des paramètres d'une caméra

2.1 Paramètres intrinsèques

Les paramètres intrinsèques permettent de modéliser la projection des points 3D de la scène sur le plan image. Ils traduisent les caractéristiques internes de la caméra (focale, taille du capteur, centre optique, etc.). Ils sont représentés par la matrice $\boldsymbol{K}$, nommée matrice intrinsèque :

$$\boldsymbol{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

avec :

— f_x, f_y : les distances focales selon les axes x et y ;
— c_x, c_y : les coordonnées du centre optique (point principal)

Sans ces paramètres les résultats qui modélisent les caractéristiques internes de la caméra seraient biaisés. Ils sont donc fondamentaux pour une bonne calibration.

2.2 Paramètres extrinsèques

Les paramètres extrinsèques décrivent la position et l'orientation de la caméra dans l'espace 3D. Ils permettent de passer du repère monde (ex : court de tennis) au repère caméra. Ils sont représentés par une matrice de taille (2×4), nommée matrice extrinsèque, donnée par :

$$[\boldsymbol{R} \mid \boldsymbol{t}] = \left[\quad \boldsymbol{R}_{3\times3} \quad \middle| \, \boldsymbol{t}_{3\times1} \, \right]$$

avec :

— $\boldsymbol{R}$: la matrice de rotation représentant l'orientation de la caméra.
— $\boldsymbol{t}$: le vecteur de translation indiquant la position de la caméra dans la scène.

En résumé, les paramètres extrinsèques assurent la transformation des coordonnées d'un point exprimé dans le repère monde vers le repère de la caméra, ce qui est essentiel pour interpréter correctement la géométrie de la scène captée.

2.3 Coefficients de distorsion

Ils corrigent les déformations dues aux lentilles de la caméra. Ils sont de deux sortes :

— la distorsion radiale : elle déforme les images en courbant les lignes droites.
— la distorsion tangentielle : elle engendre un décalage dû à un mauvais alignement lentille/capteur.

Ces distorsions sont généralement modélisées de la manière suivante :

$$x_{\text{corrigé}} = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + 2p_1 xy + p_2(r^2 + 2x^2)$$
$$y_{\text{corrigé}} = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + p_1(r^2 + 2y^2) + 2p_2 xy$$

avec :

— k_1, k_2, k_3 : les coefficients de distorsion radiale
— p_1, p_2 : les coefficients de distorsion tangentielle
— $r^2 = x^2 + y^2$

Tous ces éléments permettent de définir de manière complète les paramètres de calibration d'une caméra.

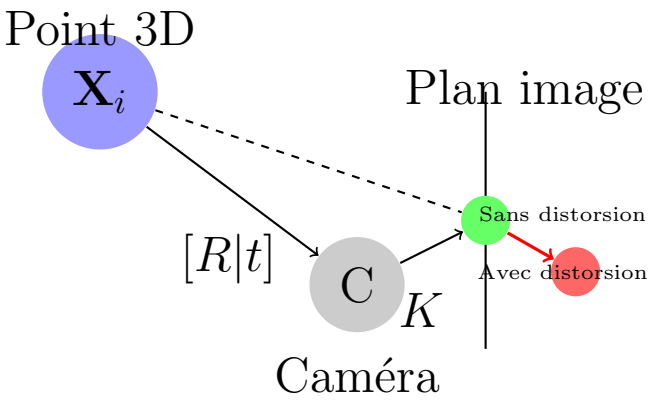
2.4 Projection sur le plan image

La projection d'un point 3D $\boldsymbol{X}_i$ sur le plan image se calcule de la manière suivante :

$$\boldsymbol{x}_i = \boldsymbol{K}\,[\boldsymbol{R} \mid \boldsymbol{t}]\,\boldsymbol{X}_i$$

Les coefficients de distorsion sont ensuite calculés pour corriger les effets optiques (déformation radiale ou tangentielle).

La figure suivante illustre ce principe de projection sur le plan image :



2.5 Résultats

Nous ne connaissons pas les véritables paramètres de la caméra utilisée pour filmer les images de notre base de données. Cependant nous sommes en mesure d'identifier les coordonnées 3D de certains points d'un terrain de tennis dans le repère monde, tels que les deux extrêmités basses et le milieu bas du filet de tennis. Nous sommes alors capables de calculer les projections sur le plan image de ces 3 points clés en utilisant les paramètres estimés de la caméra. Il nous suffit alors de comparer la valeur de ces 3 points 2D avec celle obtenu en annotant les images avec le logiciel CVAT (une présentation de ce logiciel est faite chapitre suivant). Ainsi, nous sommes capables d'évaluer la procédure d'estimation des paramètres de la caméra à partir des 14 points clés estimés par apprentissage profond. A noter que cette procédure d'estimation des paramètres de la caméra repose sur certaines opérations algébriques implémentées dans la fonction cv2.calibrateCamera d'OpenCV.

Le tableau suivant présente l'erreur (moyennée sur 3 images) de localisation en pixels de ces 3 points 2D :

Image	Erreur gauche (px)	Erreur milieu (px)	Erreur droite (px)
image1	7.29	9.13	71.58
image2	227.26	237.05	48.89
image3	332.75	63.14	382.76
Moyenne	**189.10**	**103.10**	**167.74**

Image1 donne de meilleurs résultats car elle est plus centrée et les points sont mieux alignés avec la réalité. Les erreurs des images 2 et 3 sont plus grandes car la perspective est plus inclinée et les points sont probablement moins précis.

On peut le voir sur les images des terrains suivantes :

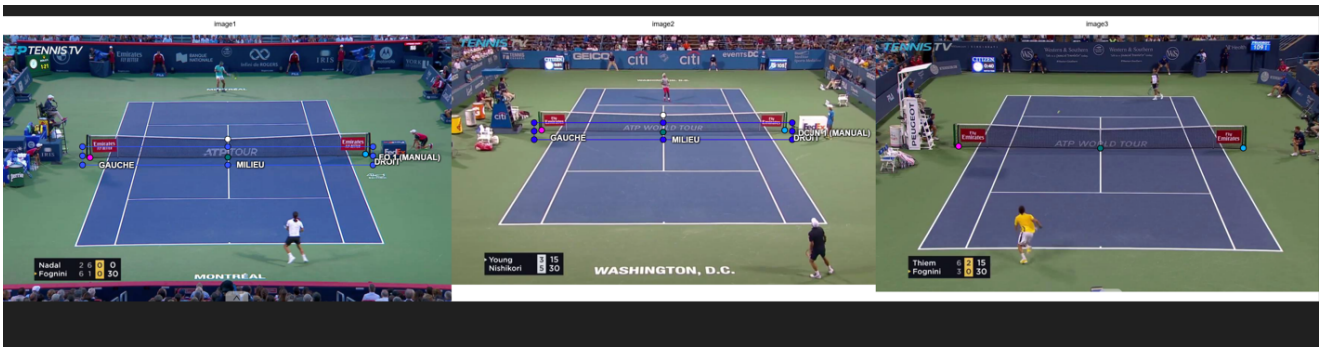


Fig. 1.5 – Images de test

.

Chapitre 2

Capture de mouvement

Le but de cette partie est d'étudier les résultats de détection des 14 articulations principales d'un joueur de tennis pendant un match. Une étude comparative sera menée entre deux approches :

— l'annotation manuelle des articulations sur des images extraites de la vidéo,
— la détection automatique à l'aide d'un modèle YOLO[Jocher et al. (2023)] pré-entraîné .

Cette analyse vise à évaluer la précision et la fiabilité des détections automatiques par rapport à une annotation de référence réalisée manuellement.

1 Annotation manuelle

L'annotation manuelle est une étape essentielle pour créer des KeyPoints permettant de mesurer la performance d'un modèle automatique.

Pour cela, nous avons utilisé le logiciel open-source CVAT (Computer Vision Annotation Tool). Il s'agit d'une plateforme conçue pour l'annotation de données visuelles (images et vidéos) dans le domaine de la vision par ordinateur. Les fonctionnalités de CVAT sont :

— la prise en charge de plusieurs types d'annotations (boîtes englobantes, points clés, polygones, etc.) ;
— l'exportation des annotations dans de nombreux formats standards (COCO, YOLO, Pascal, etc.) ;

Grâce à CVAT, nous avons pu identifier manuellement les 14 points clés du corps humain de 214 images correspondant aux différentes frames d'une même vidéo. Les résultats d'annotation sont illustrés sur la figure 2.1. Nous avons également généré un fichier qui contient les coordonnées en pixel des articulations du joueur pour chacune de ces images.



Fig. 2.1 – Annotation manuelle des articulations

2 Annotation automatique

Dans cette approche, les 14 articulations du joueur sont détectées automatiquement à l'aide du modèle YOLOv8 (version 8.0)[Jocher et al. (2023)], développé par Ultralytics. Son schéma de fonctionnement est donné par la figure 2.2.

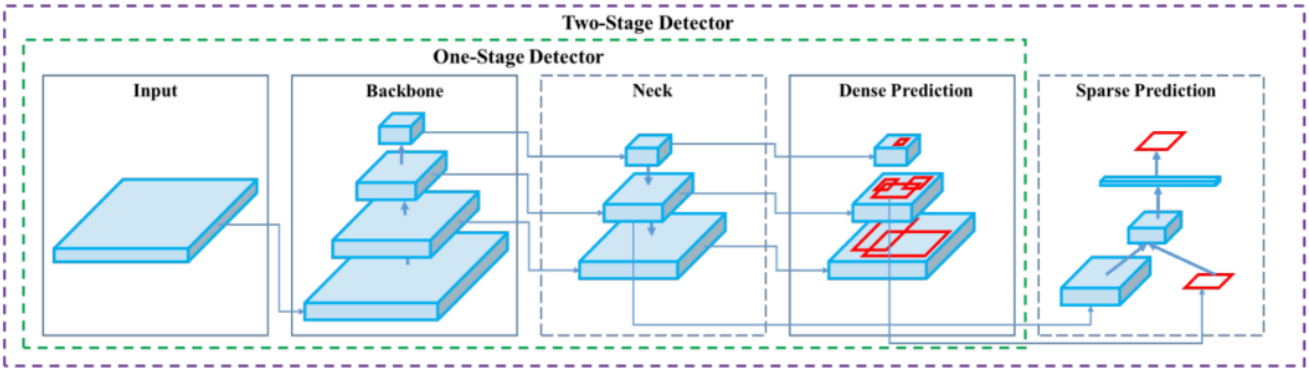


Fig. 2.2 – Schéma de fonctionnement du YOLOv8

Le processus de détection s'articule en plusieurs étapes :

- **Input** : L'image est reçue en entrée et normalisée afin de garantir un traitement optimal.
- **Backbone** : Un réseau de neurones profond extrait les caractéristiques discriminantes de l'image (formes, textures, motifs, etc.).
- **Neck** : Ces caractéristiques sont affinées pour faciliter la localisation des objets en renforçant les indices spatiaux.

— **Dense prediction** : Tous les objets potentiels sont détectés à plusieurs échelles à travers l'image.
— **Sparse prediction** : Un filtrage est appliqué (par exemple via une suppression des doublons) pour ne conserver que les détections les plus pertinentes et précises.

La figure 2.3 illustre l'objectif de la méthode sur une des images de test.

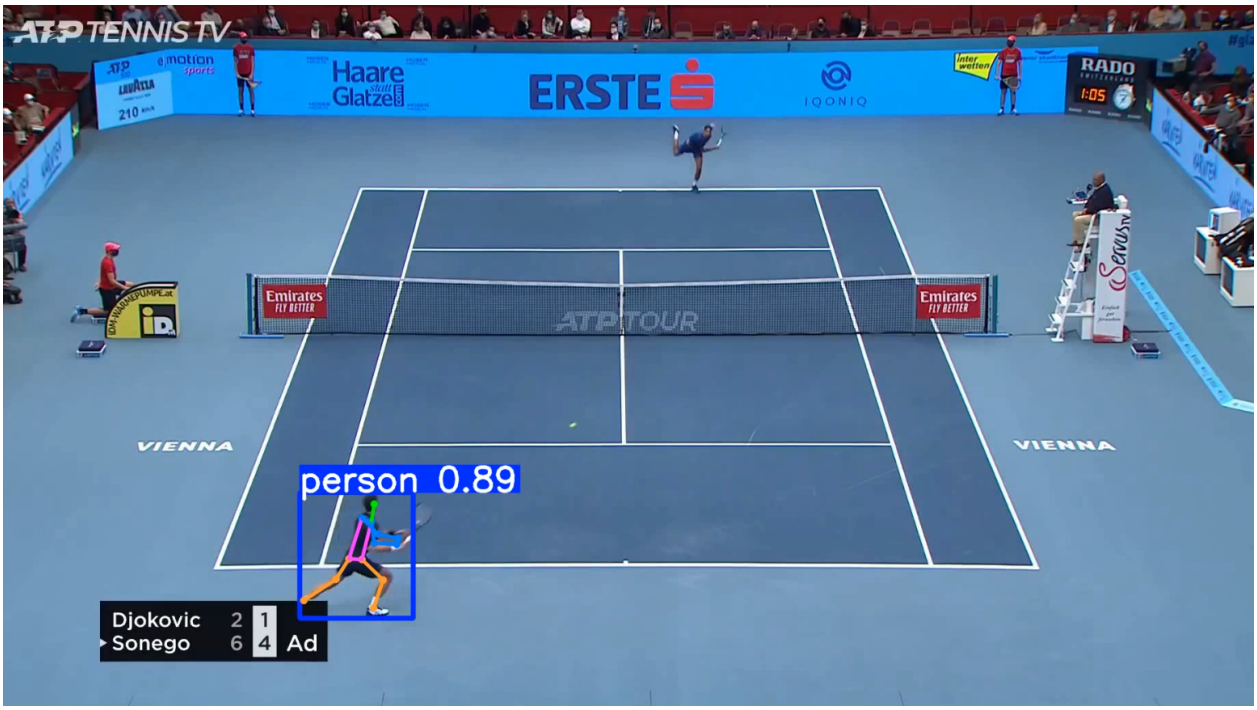


Fig. 2.3 – Annotation automatique

3 Résultats et analyse

Dans cette section, nous allons évaluer les performances de la méthode d'identification des articulations basée sur YOLOv8. Pour cela nous allons calculer pour chaque articulation de chaque image l'erreur suivante :

$$e_i = \left\| \mathbf{x}_i^{\text{true}} - \mathbf{x}_i^{\text{pred}} \right\|_2$$

avec :
— $\mathbf{x}_i^{\text{true}}$: la position 2D du point clé annoté manuellement via CVAT ;
— $\mathbf{x}_i^{\text{pred}}$: la position 2D de ce point clé prédite automatiquement par YOLOv8.

Nous avons ainsi obtenu 14 erreurs d'estimation pour chacune des 214 frames de la vidéo considérée. La figure 2.4 présente ces erreurs sous forme de diagramme en violon.

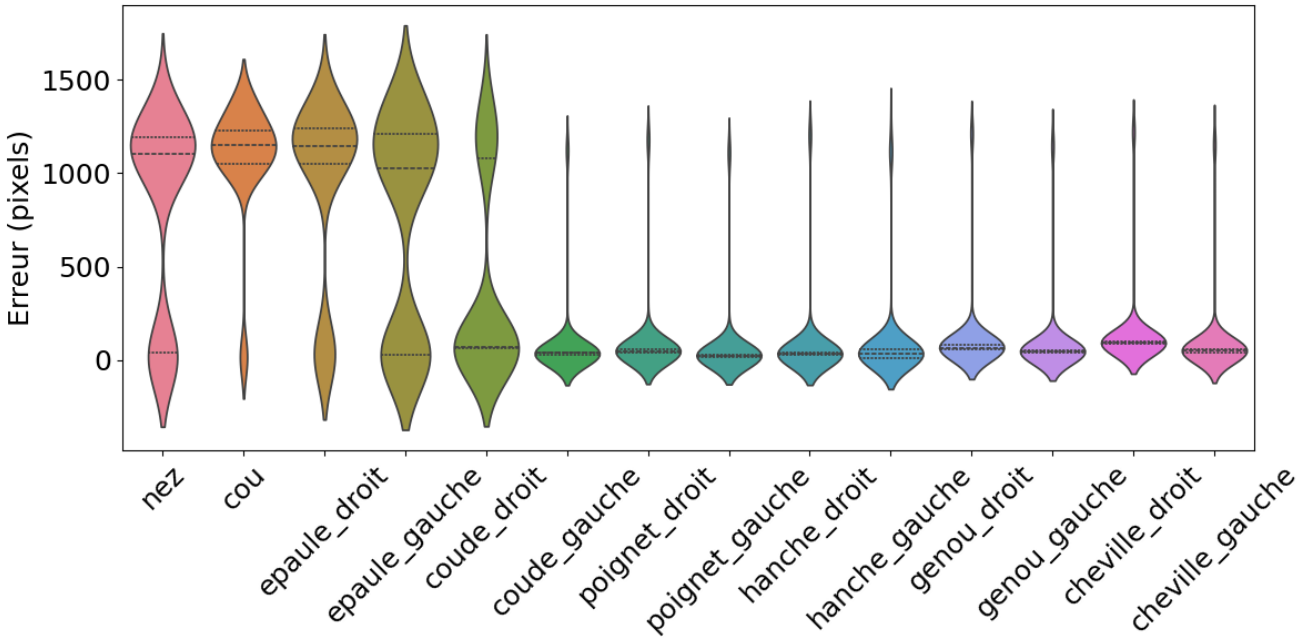


Fig. 2.4 – Erreur d'estimation des 14 points d'articulation sur les 214 frames de la vidéo considérée

La figure 2.5 présente quant-à-elle la moyenne des erreurs sur les 214 frames en fonction de la position des articulations considérée.

Ces résultats sont tout à fait normaux et cohérents. Le modèle YOLOv8 ne prend pas en charge la détection du cou, d'où une erreur très élevée sur ce point.

Les parties hautes du corps sont souvent partiellement visibles ou masquées (mouvements rapides, inclinaisons du joueur). Par exemple, sur l'annotation de la figure 2.3, le haut gauche du joueur est masqué.

Par contre, les parties basses sont bien visibles sur chaque frame, ce qui explique des erreurs plus faibles à cet endroit du corps (chevilles, genoux, hanches).

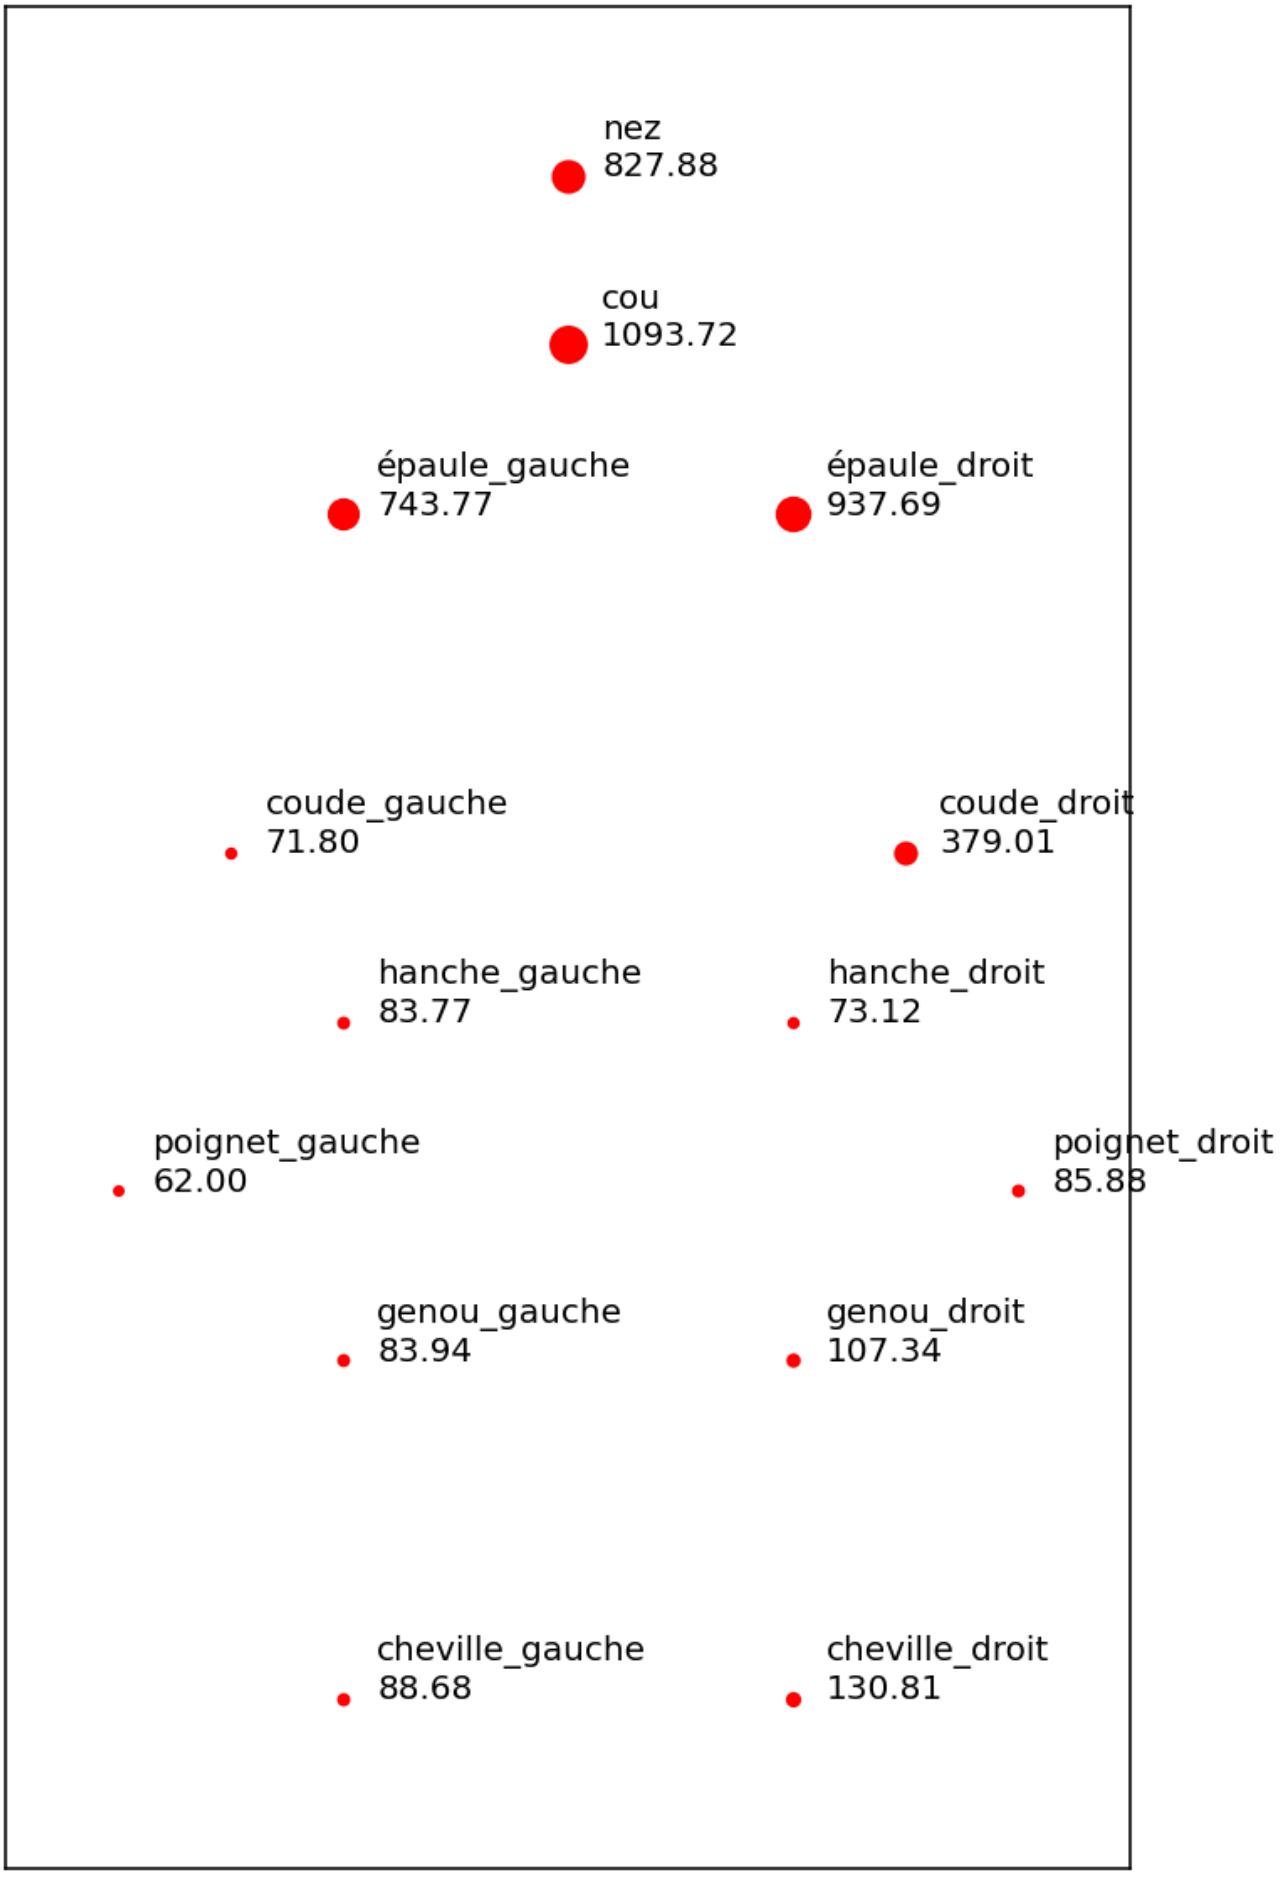


Fig. 2.5 – Moyenne des erreurs sur les 214 frames en fonction de la position des articulations considérée

Conclusion

Dans ce rapport, nous avons présenté une approche complète de calibration automatique et de capture 2D de mouvement appliquée au tennis. Cela s'est fait en utilisant un modèle d'apprentissage profond tel que le modèle ResNet pour la calibration et le modèle YOLOv8 pour la détection des articulations.

Concernant la calibration automatique, nous avons d'abord détectés les 14 intersections du terrain, puis utiliser ces points pour estimer les paramètres de la caméra. La qualité d'estimations des 14 points clés a été évaluée, montrant une erreur moyenne de 11 pixels. Ensuite, une comparaison entre les positions annotées manuellement de points 3 clés du terrain de tennis dans le plan image et leur valeur déduite par projection du repère monde vers le plan image nous a permis d'évaluer la qualité d'estimation de la procédure de calibration automatique.Les résultats d'erreur obtenus sont de l'ordre de la centaine et sont moyennement bons.

Concernant la capture de mouvement 2D, les résultats obtenus montrent que YOLOv8 peut localiser automatiquement les points clés d'un joueur avec une précision raisonnable, bien que certaines articulations restent plus difficiles à détecter de manière fiable.

Ce travail met en lumière le fait que l'utilisation de plusieurs caméras effectuant des prises de vue différentes pourrait conduire à de meilleurs résultats.Il faudrait également faire des tests sur plusieurs images.

Une autre piste d'amélioration serait de tester d'autres modèles de détection automatique tels que MediaPipe [Google Research (2023)] ou OpenPose [Cao et al. (2019)]. Par exemple, le modèle TrackNet [Tseng et al. (2018)] est souvent utilisé pour suivre la balle en temps réel.

Bibliographie

Cao, Z., Hidalgo, G., Simon, T., Wei, S.-E. & Sheikh, Y. 2019 OpenPose : Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, , vol. 43, pp. 172–186. Accessed : 2025-06-13.

Google Research 2023 MediaPipe : Cross-platform, customizable ML solutions for live and streaming media. https://github.com/google/mediapipe, accessed : 2025-06-13.

He, K., Zhang, X., Ren, S. & Sun, J. 2016 Deep Residual Learning for Image Recognition. *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778. Las Vegas, NV, USA.

Jocher, G., Chaurasia, A. & Qiu, J. 2023 Research on Traffic Sign Detection Based on Improved YOLOv8 **11** (7), 226–232.

Tseng, H.-Y., Cheng, H.-T., Chuang, Y.-Y. & Hsu, W. H. 2018 Detecting Human-Object Interaction Using a Two-Stream Recurrent Neural Network. *Asian Conference on Computer Vision (ACCV)*. TrackNet for sports ball tracking, Accessed : 2025-06-13.